Синтез речи и анализ ошибок

Индонезийский и белорусский. По три синтезатора и один распознаватель omniASR_CTC_300M_v2. Аудио подаётся в ASR на 16 кГц, декодирование greedy CTC без языковой подсказки.

Вариант включает 1 800 входов. В основном сравнении у каждой модели по 150 примеров: 25 на категорию, для повторов k = 8. В отдельном эксперименте по 25 базовых выражений при каждом k.

Индонезийский язык

Micro CER / WER, %	MMS	Supertonic	OmniVoice
Скороговорки	15,7 / 47,2	3,4 / 18,8	7,7 / 33,2
Слоговые ряды	77,1 / 100,8	44,0 / 86,4	45,6 / 88,0
Повторы (k = 8)	39,2 / 89,0	19,6 / 37,5	27,7 / 67,5
Сложные слова	18,0 / 248,0	4,1 / 88,0	11,2 / 176,0
Числительные	11,9 / 42,5	7,6 / 23,0	36,6 / 67,8
Предложения	3,8 / 21,8	1,2 / 9,2	3,0 / 19,7
Все категории	23,8 / 66,6	10,6 / 34,4	18,0 / 55,4

Белорусский язык

Micro CER / WER, %	Silero	OuteTTS	OmniVoice
Скороговорки	11,9 / 56,4	49,8 / 87,9	4,5 / 33,3
Слоговые ряды	40,3 / 88,7	80,3 / 97,2	17,9 / 63,8
Повторы (k = 8)	59,3 / 78,0	88,0 / 104,0	38,5 / 68,0
Сложные слова	41,9 / 103,8	90,2 / 126,9	26,0 / 61,5
Числительные	23,7 / 87,9	85,7 / 105,2	16,4 / 51,7
Предложения	7,2 / 28,3	71,7 / 86,1	3,0 / 17,9
Все категории	29,3 / 65,7	74,1 / 96,1	16,8 / 46,9

MMS использует встроенный голос, Supertonic F1 работает в 5 шагов, Silero использует bel_larisa. У OmniVoice 16 шагов, скорость 1. У OuteTTS температура 0,4. Фиксированные голоса FLEURS для клонирования, seed 28. Полные настройки приведены в README.

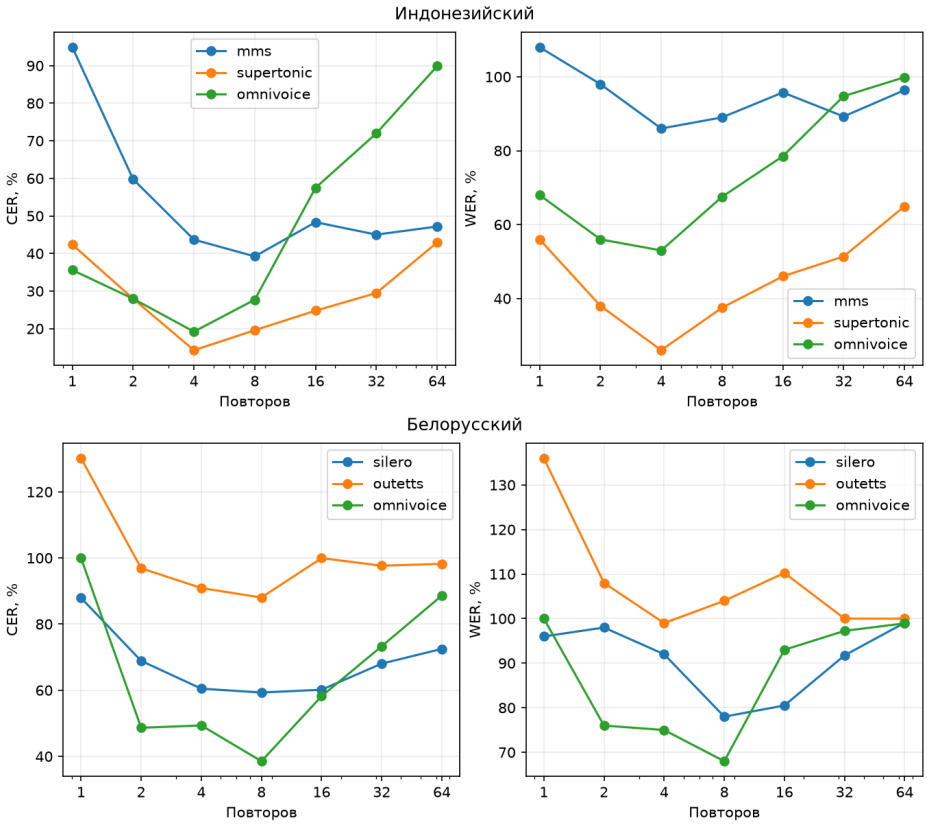
Micro складывает ошибки и длины эталонов. Полные совпадения, macro-метрики и технические сбои доступны в summary.csv. CER/WER измеряют всю цепочку TTS и ASR.

Какие свойства текста связаны с CER

Язык / модель	Символы	Повторные слова	Цепочка согласных
Индонезийский / MMS	-0,27	0,07	-0,27
Индонезийский / Supertonic	-0,22	0,04	-0,24
Индонезийский / OmniVoice	-0,35	0,11	-0,26
Белорусский / Silero	-0,22	0,30	-0,34
Белорусский / OuteTTS	-0,39	-0,19	-0,05
Белорусский / OmniVoice	-0,14	0,23	-0,18

Корреляции Спирмена на основной выборке. Последний столбец использует самую длинную последовательность согласных внутри слова.

Повторы, свойства текста и разбор ошибок



Результаты

Индонезийский. Наименьшая micro CER у Supertonic (10,6%), наибольшая у MMS (23,8%). Полных совпадений у Supertonic: 42,0%.

Белорусский. Наименьшая micro CER у OmniVoice (16,8%), наибольшая у OuteTTS (74,1%). Полных совпадений у OmniVoice: 28,0%.

Наибольшее по модулю изменение WER между k = 1 и k = 64 у OuteTTS (белорусский): 136,0% и 100,0% соответственно. Между точками сравниваются одни и те же 25 базовых выражений.

Среди проверенных связей с CER в основной выборке наибольшее по модулю значение с числом фонем у OuteTTS (белорусский, ρ = -0.40, n = 150). Категории и признаки могут быть связаны между собой.

Примеры распознавания

OmniVoice / in_05_08. Эталон «empat puluh empat». ASR «[пусто]». CER 100,0%, WER 100,0%.

Silero / be_04_03. Эталон «вялікдзень». ASR «vjelikcin». CER 100,0%, WER 100,0%.

Проверка на слух

Прослушано по 10 записей на язык. Полные субъективные наблюдения сохранены в listening_notes.json. На слух оценивались разборчивость, темп, шумы и естественность голоса.

Индонезийский. Повторы Supertonic оценены очень хорошо. У MMS высокий темп затруднял разбор длинного повтора. У OmniVoice повтор к концу переходил в шум, а числительное in_05_08 было неразборчиво. Обычная фраза OmniVoice воспринималась как естественная речь с плохим качеством записи.

Белорусский. У Silero заметен синтетический голос, но слова различимы. Длинный повтор OuteTTS неразборчив, в коротких записях слышны шумы. У OmniVoice в длинном повторе слышны другие слова, при этом обычная фраза и числительное звучат очень чётко.

Оценка на слух и метрики расходятся на отдельных примерах. Чёткое по оценке слушателя «трыццаць тры» (OmniVoice, be_05_07) получило CER 116,7% и WER 100,0%: ASR выдал символы другого алфавита. Слоговой ряд Supertonic также оценён хорошо при WER 100%. Шум, темп и естественность не измеряются CER/WER напрямую. Ошибки всей цепочки требуют проверки на слух.